資訊檢索與文字探勘導論

hw4 Report

B03705012 張晉華

1. 程式語言

Python 3.5.2

2. 執行環境

Linux OS (Ubuntu 16.04 LTS)

Python3 Packages Requirements:

- Python Natural Language Toolkit(nltk 3.2.2)
- Python Numpy(1.13.3)

3. 執行方式

- **Package Installation**
  - Python Natural Language Toolkit(NLTK)

    Step1：Install Packages

    (可以透過 pip3 install nltk 安裝)

    Step2：Corpus Download

    有兩個 Corpus 需要下載以供程式使用：punkt(tokenize 需要)和 stopwords

    可以在 python3 環境下執行 nltk.download()下載

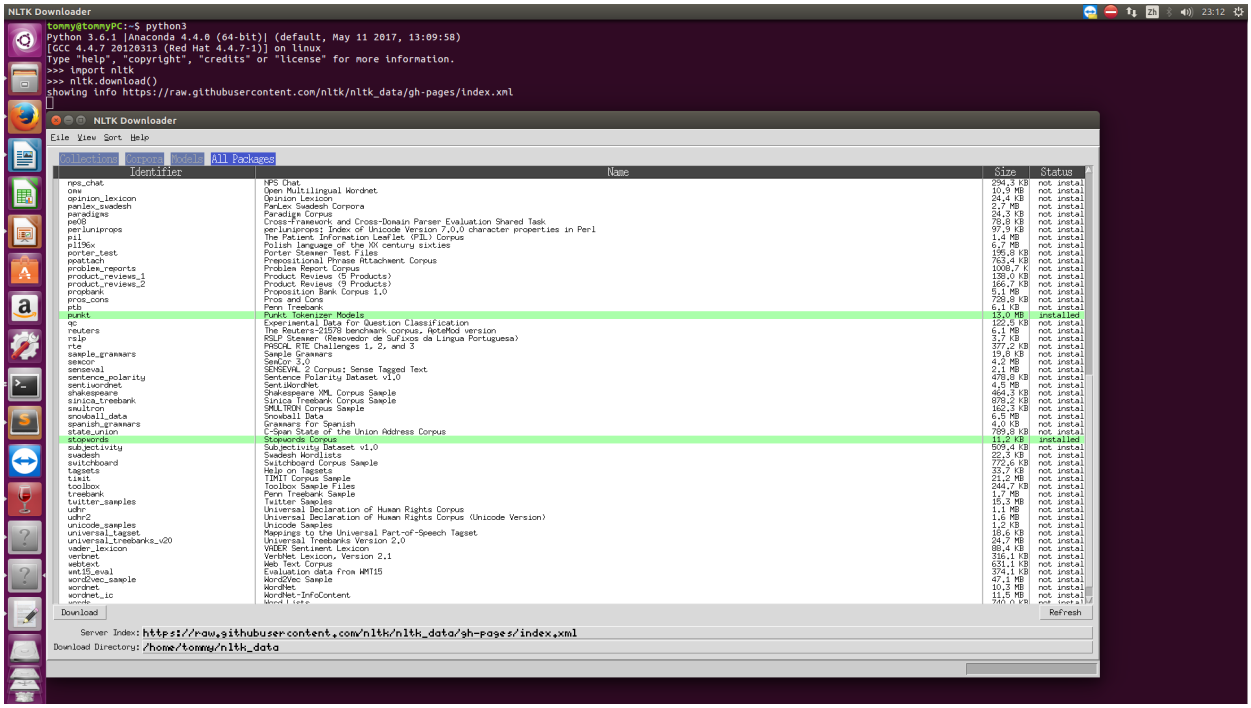

- Python Numpy：可透過 pip3 install numpy 安裝

- **執行指令**
  - 首先確定同路徑內有 data/IRTM/(1095 篇文檔)、my_tokenizer.py、my_dictionary.py、my_cosine.py、cluster.py 4 個項目
  - cd 進程式所在路徑，在 termial 執行 python3 cluster.py，檔案結果產出在同一路徑的 8.txt、13.txt、20.txt，內容為 3 個 K 值的 cluster 結果。

4. 作業處理邏輯說明

- **cluster.py**

  分為 pre_process,cluster,output 3 個大步驟

  - pre_process

    利用 hw2 的 code 建立好每個文章的 normalized tfidf vectors.並且算好每兩篇文章之間的 cosine similarity 並丟進 heap 內排序。

  - cluster
    - 合併部份
      - 利用並查集的結構優化，用一張表紀錄這個文章被併入哪個文章的群中（如果沒有則值為自己），以及自己本身又併入了多少的文章，如果需要尋找這個文章群的根則利用遞迴就可以找到。
    - Single Link
      - 將 pre_process 處理好的 heap 依序取出，若取出的兩個文章目前屬於不同群，則代表他們會是現存所有群之中 single link 最短的，則將兩群合併，重複此步驟直到現存文章群的數量=K。
    - Centroid
      - 一樣從 heap 依序取出，若取出的兩個文章目前屬於不同群則合併，而合併後要將根節點的文章 vector 更新成合併後新的 centroid（用根結點代表新群的 centroid），並且刪去原本 heap 內所有有取出的這兩個文章的點對，並加入新算出來的 centroid 與其他文章群根節點的 cosine similarity，重複此步驟直到現存文章群的數量=K。

  - output

    利用遞迴的方式找到每一篇文章在並查集內的根節點，同一個根節點的文章就代表在同一個群裡面，再將結果輸出成 txt 檔。

執行截圖如下頁圖：

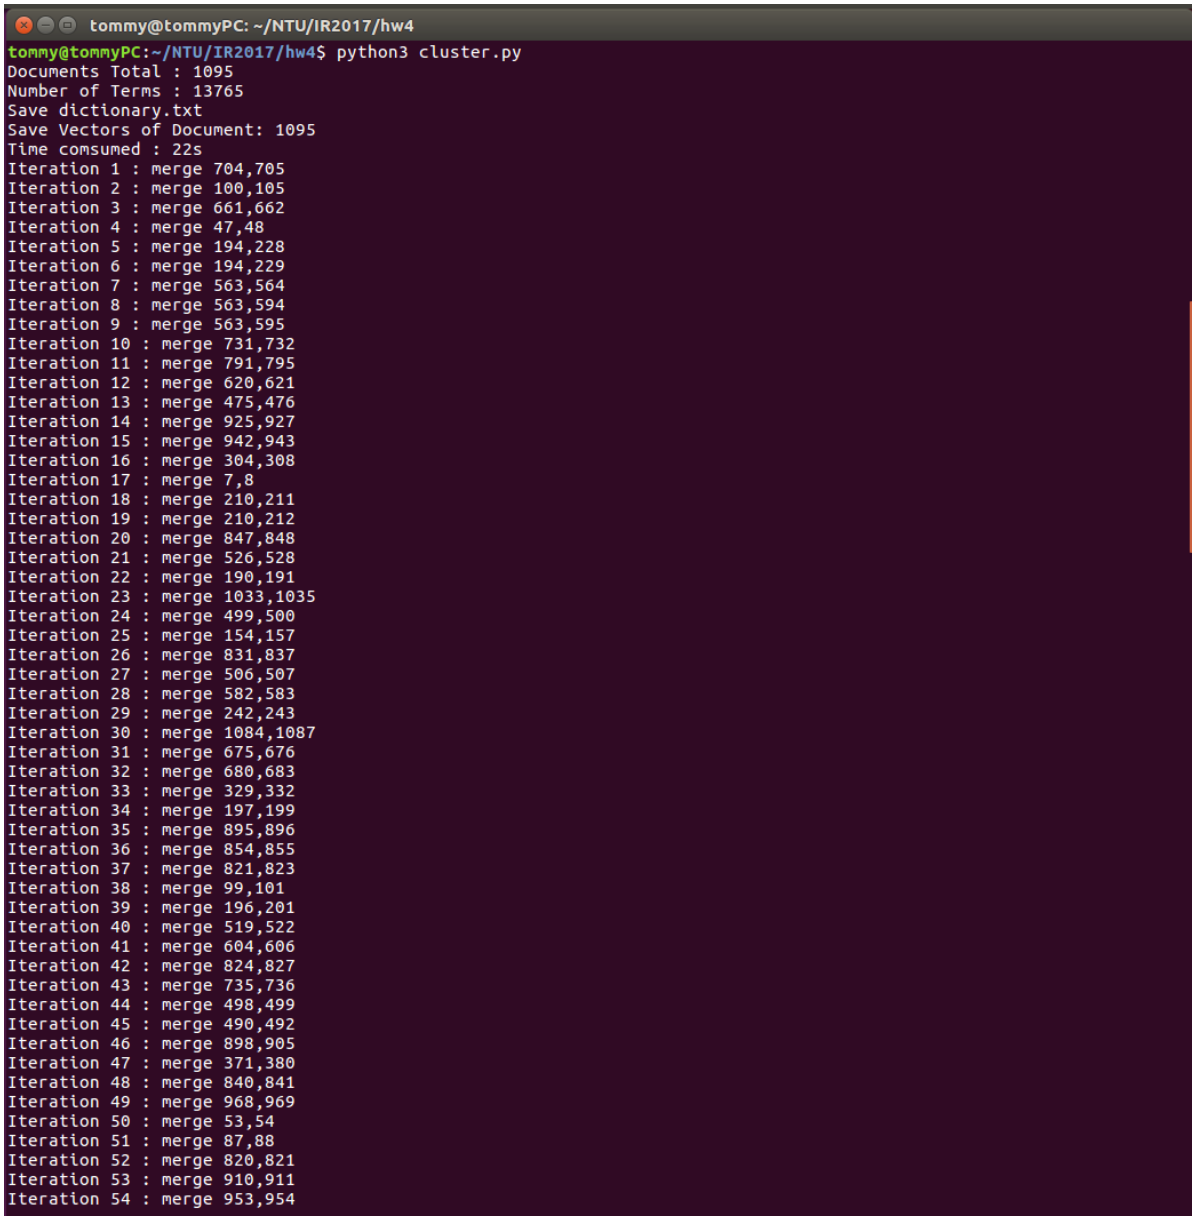

由於 Iteration 較多無法完整截圖，執行上程式會印出每次 Iteration 合併的兩個文章群根節點的編號，由於 K 值最小是 8，因此程式會在 Iteration 1087 停止。

5. 心得

這次的作業實作了兩種 Similarity measure between clusters 的方法：Single Link 和 Centroid，而兩個作法的結果截然不同，Single Link 容易出現大者恆大的現象，結果出來會容易形成一兩個大群配上其他只有一兩篇文章的群，而 Centroid 相對來說就較為集中，因此這次最後我選擇用 Centroid 的方法，如果以後有需要再實作 clustering 的算法時，應該要多注意多思考，哪種方法表現會比較好，避免用錯方法導致表現不佳的情況出現。